

# Maschinelles Lernen (ML)
# Das Lernproblem (Supervised Learning)

Dr.-Ing. Christoph-Alexander Holst

Themen 2. Block

**Daten**

**Datenrepräsentation**

**Targets, Labels und Train/Test-Split**

**Hypothese, Hypothesenraum und Lerner**

**Wie viel Daten sind genug?**

# Daten

# Daten

Zu einem Datensatz *D* gehört mehr als nur „Messwerte“

$$D = \{(x_i, y_i)\}_{i=1}^{N}$$

Die eigentlichen Daten: $x_i \in X$

Label: $y_i \in Y$

# Daten

**Tabellarische Daten**

Ein Datenpunkt:

$$x_i = \{x_{i1}, x_{i2}, x_{i3}, \ldots, x_{id}\}$$

Beispiele:
- Alter, Blutdruck, Laborwerte
- Temperatur, Drehzahl, Stromaufnahme
- Einkommen, Käufe, Kundendaten

| Variable Name | Role | Type | Demographic | Description |
|---|---|---|---|---|
| subject# | ID | Integer | | Integer that uniquely identifies each subject |
| age | Feature | Integer | Age | Subject age |
| test_time | Feature | Continuous | | Time since recruitment into the trial. The integer part is the number of days since recruitment. |
| Jitter(%) | Feature | Continuous | | Several measures of variation in fundamental frequency |
| motor_UPDRS | Target | Continuous | | Clinician's motor UPDRS score, linearly interpolated |

Tsanas, A. & Little, M. (2009). Parkinsons Telemonitoring [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5ZS3N.

# Daten

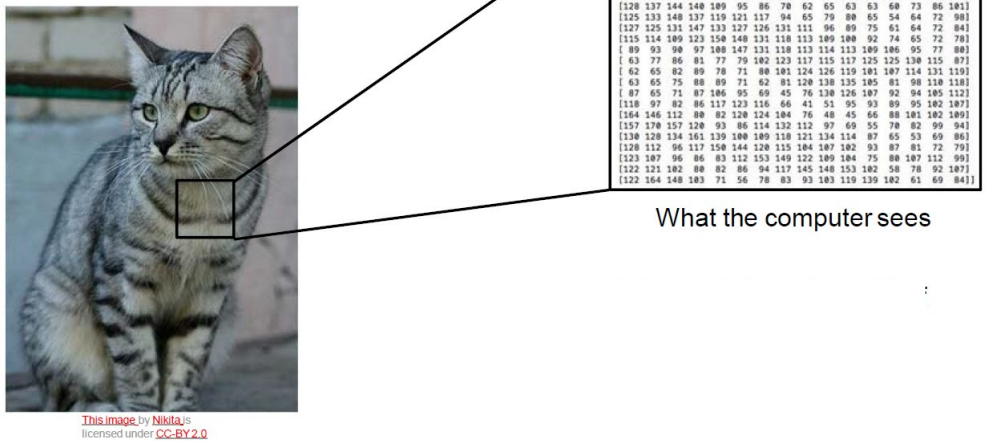
**Bilder / räumlich strukturierte Daten**

Bilder besitzen eine ausgeprägte räumliche *Lokalität*.

Benachbarte Pixel sind nicht unabhängig; lokale Nachbarschaften bilden Kanten, Texturen und Formen.

(Beispiel „Fell“: Es ist unwahrscheinlich, dass ein von grauen Pixeln umgebenes Pixel pink ist. )

Geeignete Modelle wie CNNs nutzen die Lokalität explizit aus, indem sie lokale Filter auf benachbarte Pixel anwenden.



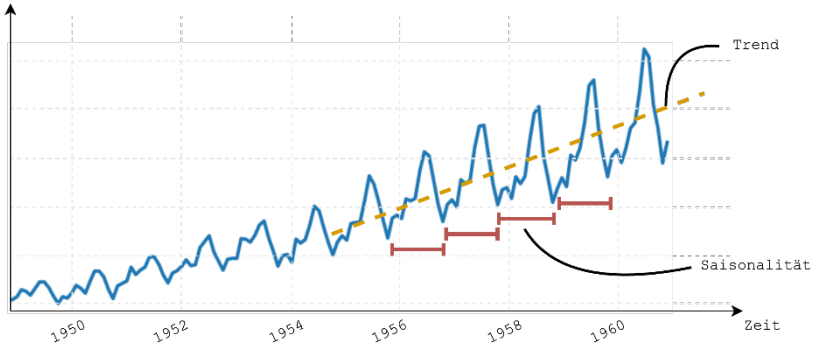

This image by Nikita is licensed under CC-BY 2.0

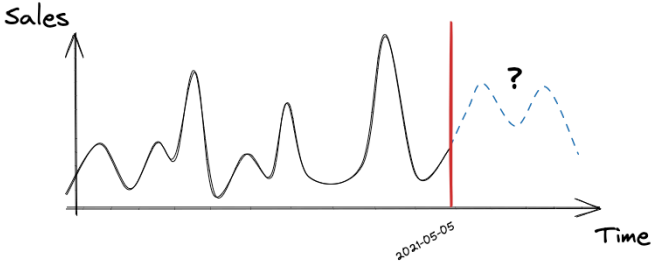
# Daten

**Sequenzielle Daten**

- Zeitreihen
- Sensorsignale
- Audio
- Text
- Events
- Warenstände
- Nutzerverhalten

Eine zufällige Permutation würde die Bedeutung verändern.



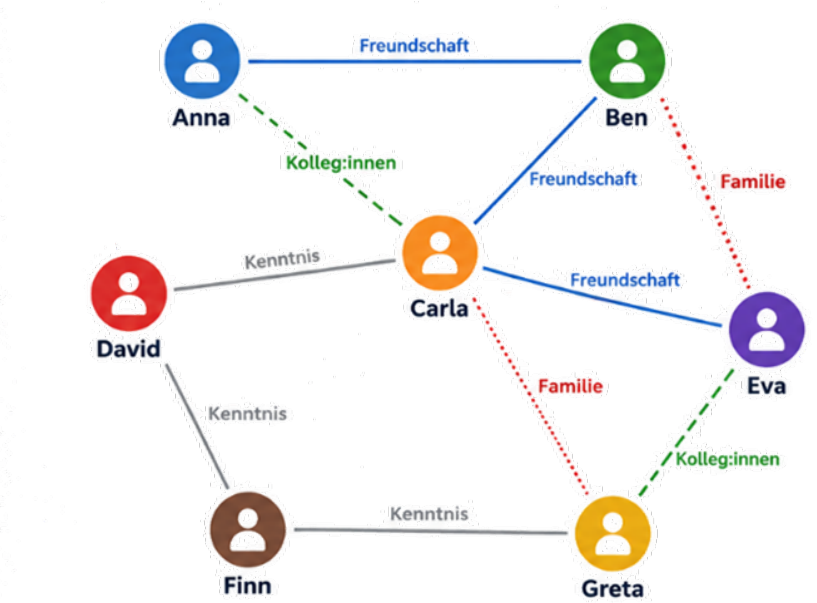

| Time | Sales |
|---|---|
| 2021-04-03 | 24 |
| 2021-04-13 | 52 |
| 2021-04-21 | 72 |
| 2021-04-29 | 45 |
| 2021-05-05 | ? |
| 2021-05-14 | ? |

# Daten

**Relationale Daten**

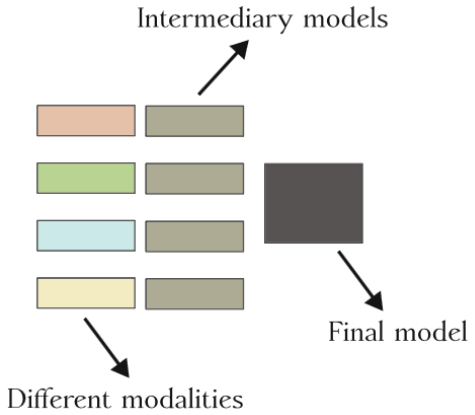
- soziale Netzwerke
- Moleküle
- Stromnetze
- Knowledge Graphs

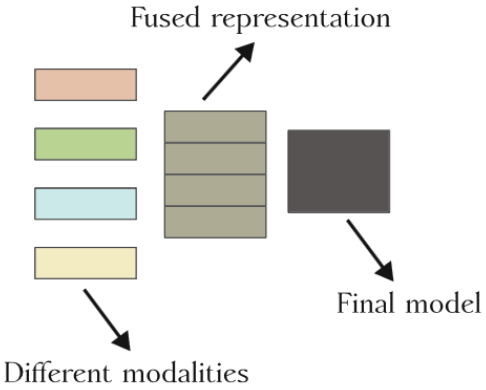
Hier liegt Information nicht nur in einzelnen Objekten, sondern in deren Beziehungen zueinander.



**Multimodale Daten und Information Fusion**

- Bild + Text
- Sensordaten + Wartungsbericht
- medizinisches Bild + Laborwerte + Arztbrief




Bilder aus Škrlj, Blaž. *From unimodal to multimodal machine learning*. Springer, 2024.

# Datenrepräsentation (Merkmale / Features)

# Datenrepräsentation

Ein Lernalgorithmus arbeitet nie direkt mit „der Realität“, sondern immer mit einer Repräsentation der Realität. Merkmale sind die Größen, in denen wir diese Repräsentation ausdrücken. Selbst Rohdaten sind immer nur eine Repräsentation der Realität.

Die wichtige Fragestellung: „Welche Repräsentation macht die für die Aufgabe relevante Information für den Lerner zugänglich?“

$$\phi\colon\ X_{\text{raw}} \mapsto X_{\text{feature}}$$

Warum Merkmale extrahieren?

1. Rohdaten enthalten häufig viel Information, die für die Aufgabe irrelevant ist
2. Rohdaten können extrem hochdimensional sein
3. Gute Merkmale bauen Vorwissen/Expertenwissen über das Problem ein
4. Gute Repräsentationen können das eigentliche Lernproblem einfacher machen

# Datenrepräsentation

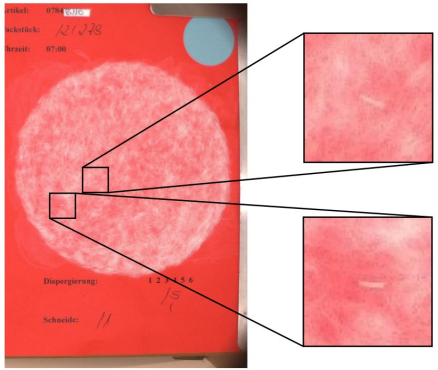
## Maschinenzustands-überwachung



Rohdaten: Vibrationssignal

Merkmale:
- Statist. Werte (z.B. Kurtosis)
- Spektralenerige
- Max. Amplitude
- …

## Bild-klassifikation[1]



Rohdaten: Pixel

Merkmale:
- Kanten
- Texturen
- Regionale Helligkeitswerte
- …

## Textvorhersage



Rohdaten: Text

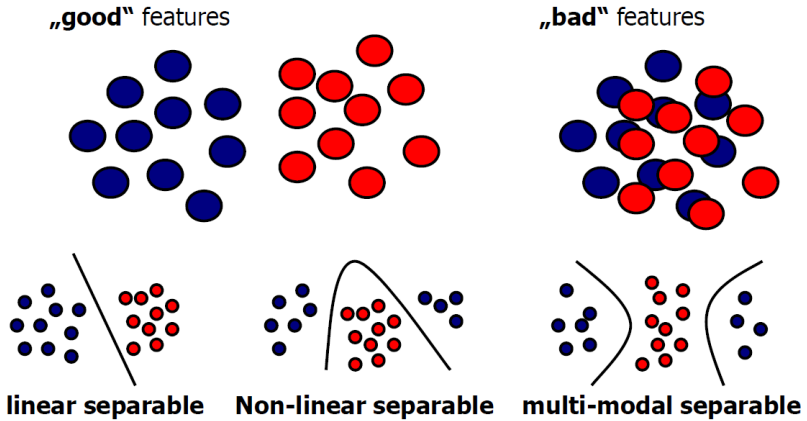
Merkmale:
- Cosinus-Ähnlichkeit
- Embeddings
- …

[1]Ehlenbröker, Jan, Christoph-Alexander Holst, and Volker Lohweg. "Quality Control in Plastic Fiber Production: Overcoming Scarce Data with Explainable AI." *2025 IEEE 30th International Conference on Emerging Technologies and Factory Automation (ETFA)*. IEEE, 2025.

# Datenrepräsentation

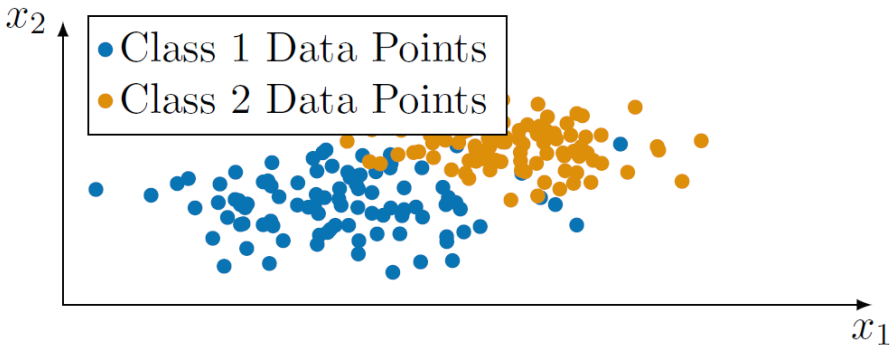
Ein gutes Feature ist möglichst:

- **relevant** für das Ziel,
- **informativ/diskriminativ**,
- **robust** gegenüber irrelevanten Veränderungen,
- **stabil** zwischen Training und Anwendung,
- **verfügbar**, wenn später tatsächlich vorhergesagt wird,
- möglichst wenig redundant zu vorhandenen Features.

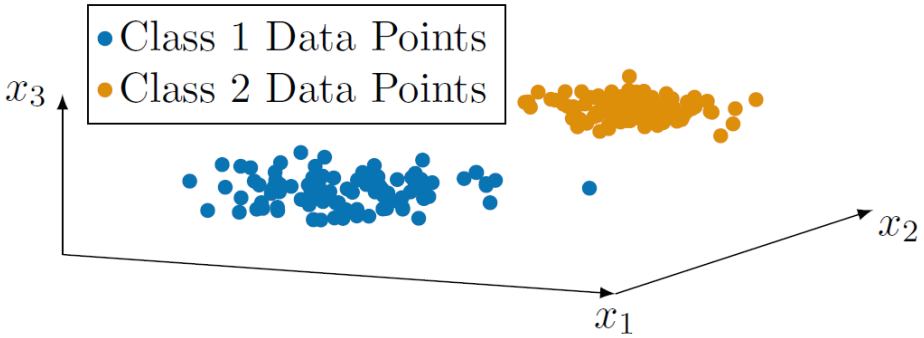


# Datenrepräsentation

Sind mehr Merkmale automatisch besser?




Zwei Merkmale: nicht separierbar

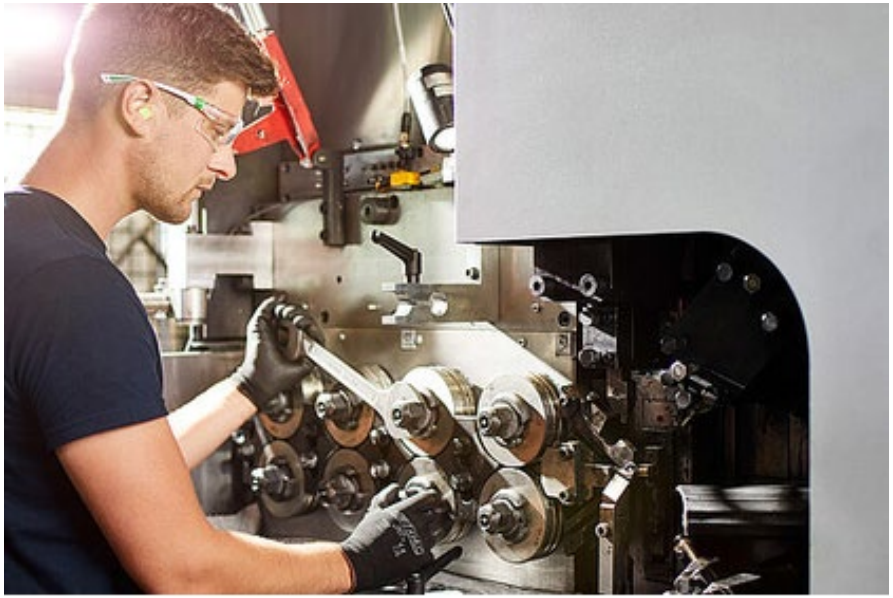


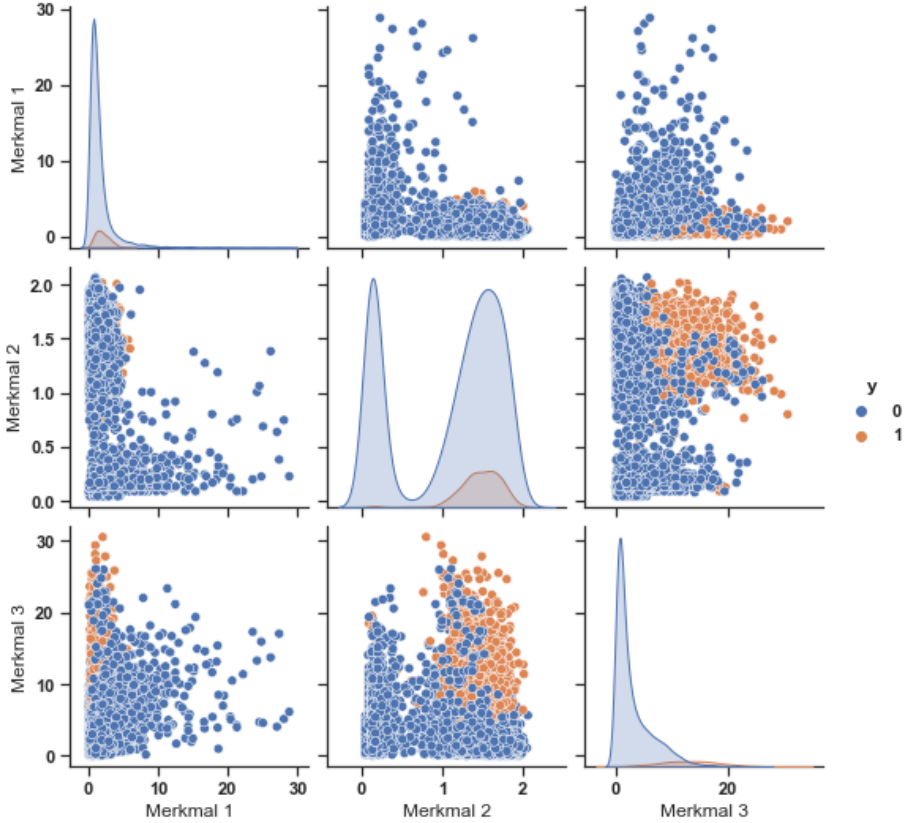

Drei Merkmale: separierbar

Holst, Christoph-Alexander. *Designing Possibilistic Information Fusion Systems: Redundancy as Criterion for Fusion Topologies*. Springer Nature Switzerland , 2026.

# Datenrepräsentation

Sind mehr Merkmale automatisch besser?





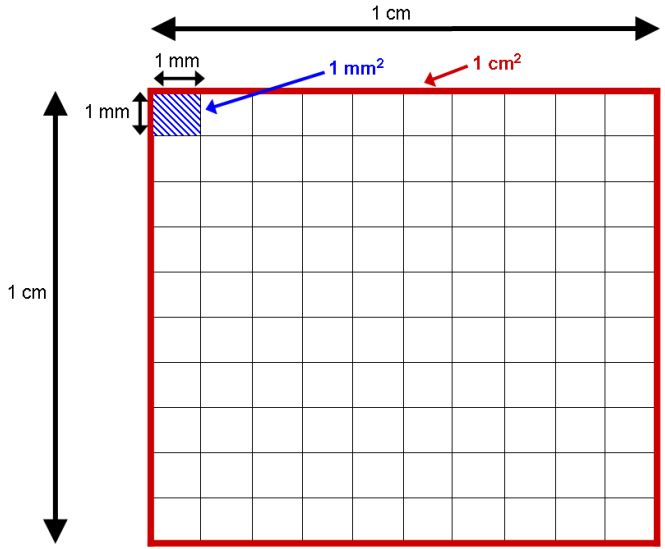

Holst, Christoph-Alexander. *Designing Possibilistic Information Fusion Systems: Redundancy as Criterion for Fusion Topologies*. Springer Nature Switzerland , 2026.

# Datenrepräsentation

Sind mehr Merkmale automatisch besser?

Aber Merkmale können auch

- **irrelevant sein**: bringen primär Rauschen in die Repräsentation.
- **redundant sein**: bringen kaum oder sogar keine neue Information.




Negative Folge:

- Zu viele Dimensionen

Mehr (unnötiger) Trainingsaufwand und schwerer zu lernendes Problem

→ Curse of Dimensionality

Holst, Christoph-Alexander. *Designing Possibilistic Information Fusion Systems: Redundancy as Criterion for Fusion Topologies*. Springer Nature Switzerland , 2026.

# Targets, Labels und Train/Test-Split

# Targets, Labels und Train/Test-Split

Zu einem Datensatz *D* gehört mehr als nur „Messwerte“

$$D = \{(x_i, y_i)\}_{i=1}^{N}$$

Die eigentlichen Daten: $x_i \in X$

Label: $y_i \in Y$

# Targets, Labels und Train/Test-Split

Was ist *y*?

Klassifikation: $y \in \{0, 1, \ldots, K-1\};\ K \in \mathbb{N}_{>0}$

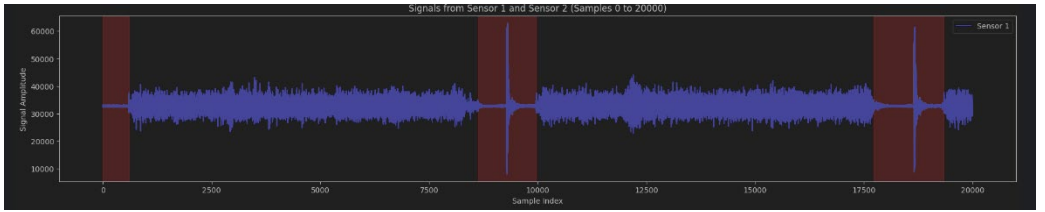
Regression: $y \in \mathbb{R}$

Wo kommt *y* eigentlich her?

- Supervision: Menschliche Fachexperten !

# Targets, Labels und Train/Test-Split

Windemaschine produziert ~1 Stahlfeder/s
86400 Federn pro Tag
4 Wochen Messkampagne




Vibrationsdaten für 1 Feder

Targetvariable
Produktionsgüte: Wo Label für gute / schlechte Federn hernehmen?
Maschinenzustand: Wie objektiv bewerten?
Werkzeugverschleiß: Wer bewertet das?

# Targets, Labels und Train/Test-Split

Was ist *y*?

Klassifikation: $y \in \{0, 1, \ldots, K-1\};\ K \in \mathbb{N}_{>0}$

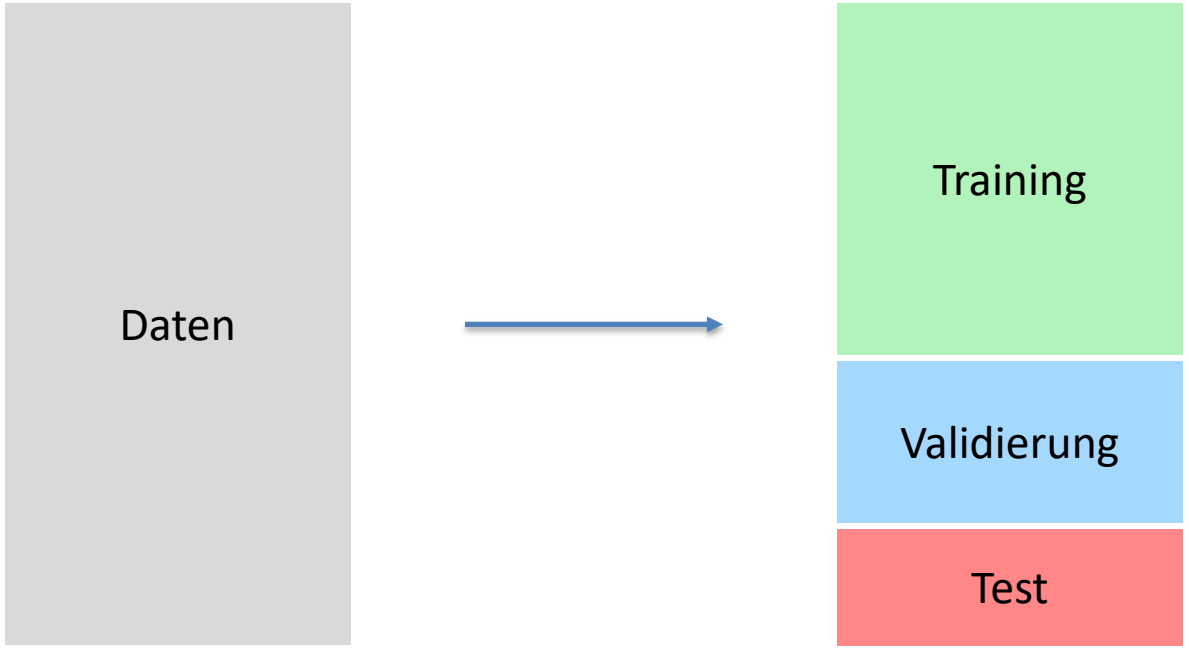
Regression: $y \in \mathbb{R}$

Wo kommt *y* eigentlich her?

- Supervision: Menschliche Fachexperten !
- Weak Supervision: Programmatisches Labeling (Heuristiken, Labeling-Funktionen)
- Implizites Feedback: z.B. Logdaten & Telemetrie, Nutzerinteraktionen
- LLM-as-a-Judge (Vorsicht!)
- Semi-Supervised Learning (Ein Modell lernt auf wenigen gelabelten Daten und labelt dann selbst weitere Daten.
- Self-Supervised Learning (Label existieren implizit in den Daten; einzelne Daten werden z.B. durch Maskierung vorenthalten und dienen als Target bzw. Label).

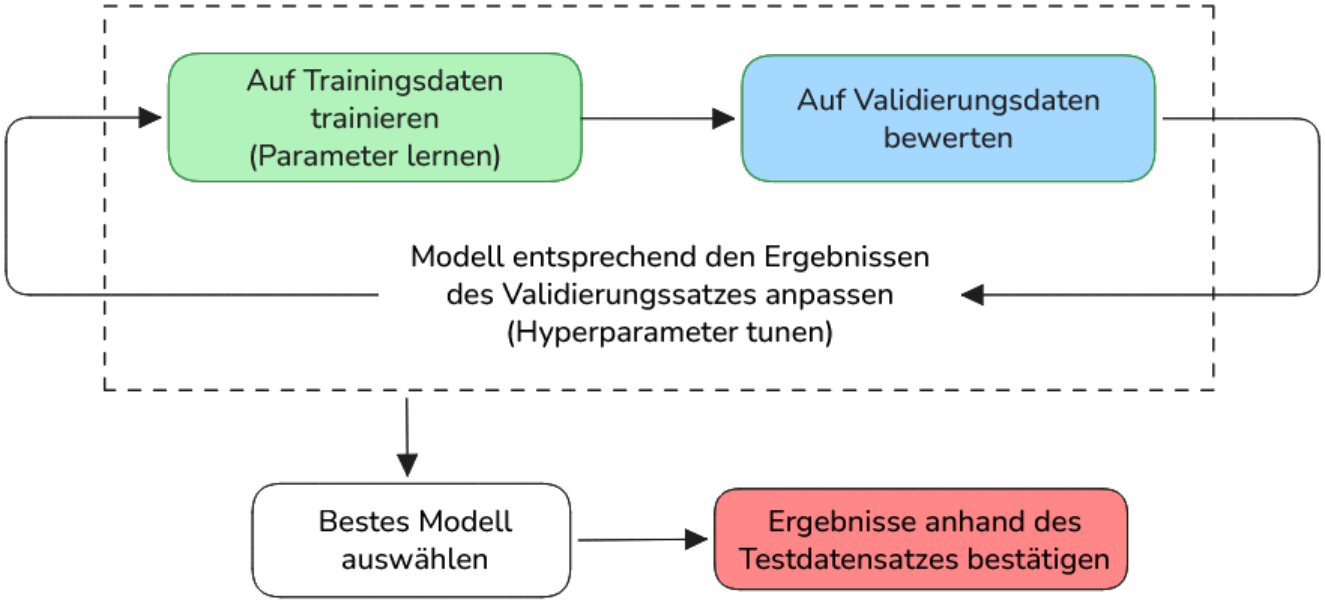
# Targets, Labels und Train/Test-Split

Trainings- / Testsplit: Zurückhalten von Daten zur Bewertung des Modells




$$D = D_{train} \cup D_{val} \cup D_{test}$$

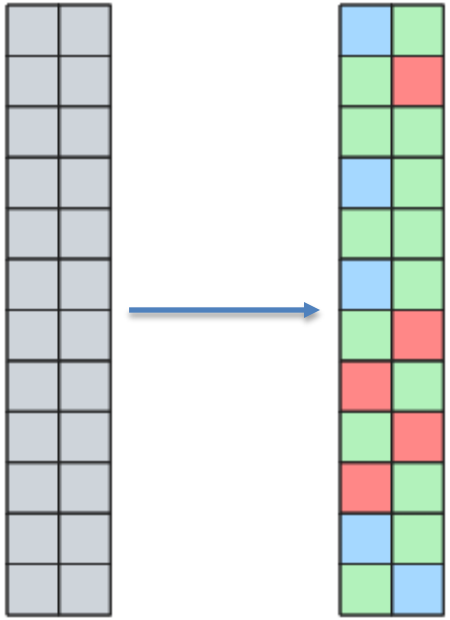
# Targets, Labels und Train/Test-Split



# Targets, Labels und Train/Test-Split

## Bei unabhängigen Daten

ohne sequentielle Abhängigkeiten oder Lokalitäten
→ Random Splits



## Zeitreihen

Temporale Abhängigkeit beachten
Random Splits nicht sinnvoll

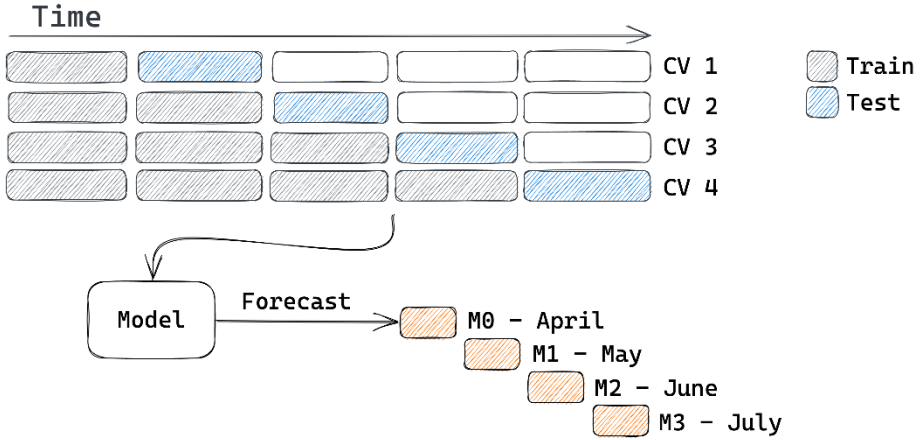



*Abbildung aus Projekt Arbeitswelt.Plus / MKIFusion

# Targets, Labels und Train/Test-Split

Data Leakage (Achtung!) **Target Leakage**

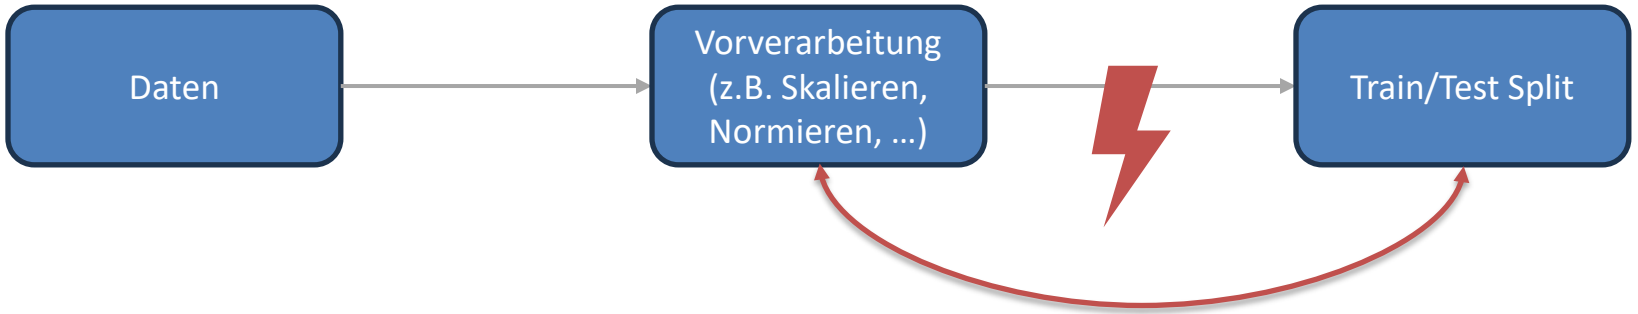
**Aufgabe:** Eine Bank möchte bei Eingang eines Kreditantrags vorhersagen, ob das Jahreseinkommen einer Person über 60.000 € liegt.

| | | | | | | | Für die Bank nicht bekannt | |
|---|---|---|---|---|---|---|---|---|
| Antragsteller | Alter | Ausbildung | Berufserfahrung | Branche | Wochenarbeitszeit | Einkommensteuer Vorjahr | Nettogehalt /Monat | Target: Einkommen > 60.000 €? |
| A | 26 | B.Sc. | 2 Jahre | IT | 40 h | 8.200 € | 2.650 € | Nein |
| B | 34 | M.Sc. | 8 Jahre | Maschinenbau | 40 h | 18.500 € | 3.950 € | Ja |
| C | 29 | Ausbildung | 6 Jahre | Logistik | 38 h | 9.100 € | 2.850 € | Nein |
| D | 42 | M.Sc. | 16 Jahre | Pharma | 40 h | 27.300 € | 5.200 € | Ja |
| E | 37 | B.Sc. | 11 Jahre | Verwaltung | 39 h | 11.400 € | 3.050 € | Nein |
| F | 48 | Promotion | 20 Jahre | Forschung | 42 h | 32.600 € | 5.850 € | Ja |

# Targets, Labels und Train/Test-Split

Data Leakage (Achtung!)

**Train/Test Leakage**




Datenverarbeitung erst nach dem Split ausführen!

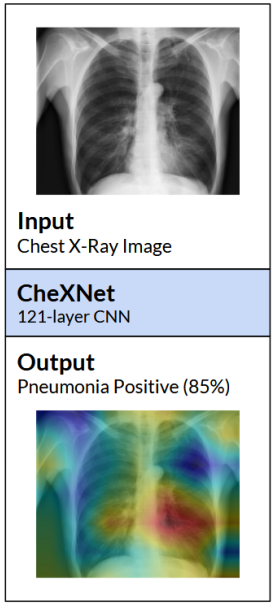
Das Testset darf den Trainingsprozess in keiner Weise beeinflussen – auch nicht indirekt über Preprocessing.

# Targets, Labels und Train/Test-Split

Data Leakage (Achtung!)

**Group Leakage**

Nicht alle Samples im Datensatz sind unabhängig voneinander




Daten:
12120 frontale Bruströntgenbilder
30805 Patienten
~4 Bilder pro Patient

„For the pneumonia detection task, we randomly split the dataset into training (28744 patients, 98637 images), validation (1672 patients, 6351 images), and test (389 patients, 420 images). “

„There is no patient overlap between the sets.“

Rajpurkar, Pranav; Ng, Andrew et al. "Chexnet: Radiologist-level pneumonia detection on chest x-rays with deep learning." *arXiv preprint arXiv:1711.05225* (2017).

# Hypothese, Hypothesenraum und Lerner

## Das eigentliche Lernproblem

Es gibt irgendeine unbekannte Beziehung: $f^*: X \to Y$

Wir besitzen lediglich Beispiele (Samples): $D = \{(x_i, y_i)\}_{i=1}^{N}$

Wie lernen daraus eine Approximation (Hypothese): $h: X \to Y$

# Hypothese, Hypothesenraum und Lerner

Beispiel: Ist ein Auto ein Familienauto?*

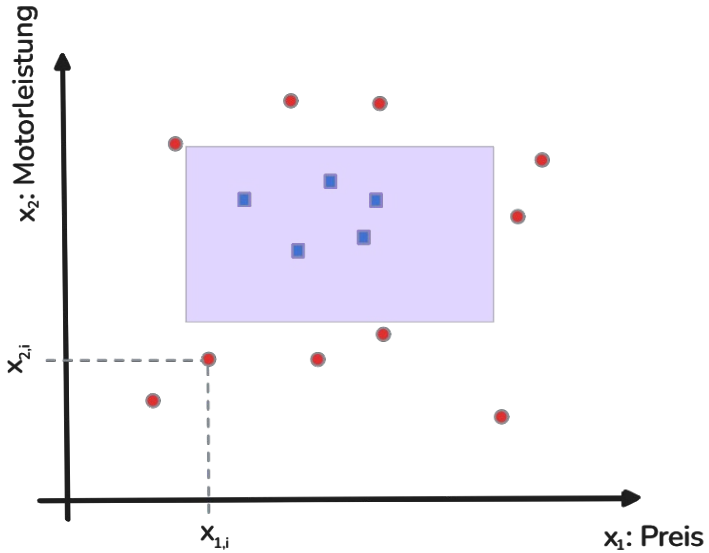
$$x_1 = \text{Preis}$$
$$x_2 = Motorleistung$$

$$y = \begin{cases} 1 & \text{Familienauto} \\ 0 & \text{kein Familienauto.} \end{cases}$$

Hypothesenraum / Modellklasse *H*: Familie an Funktionen, die unser Lerner in Betracht ziehen darf/kann.

Beispiel: Experten sagen
$x_{1,1} < Preis < x_{1,2}$; $x_{2,1} < Leistung < x_{2,2}$
=> $H = \{\text{Rechtecke}\}$

→ *H* wird vorm Training festgelegt.
Damit ist *H* ein Hyperparameter




*aus Alpaydin, Ethem. *Introduction to Machine learning*. MIT press, 2021.

# Hypothese, Hypothesenraum und Lerner

Beispiel: Ist ein Auto ein Familienauto?*

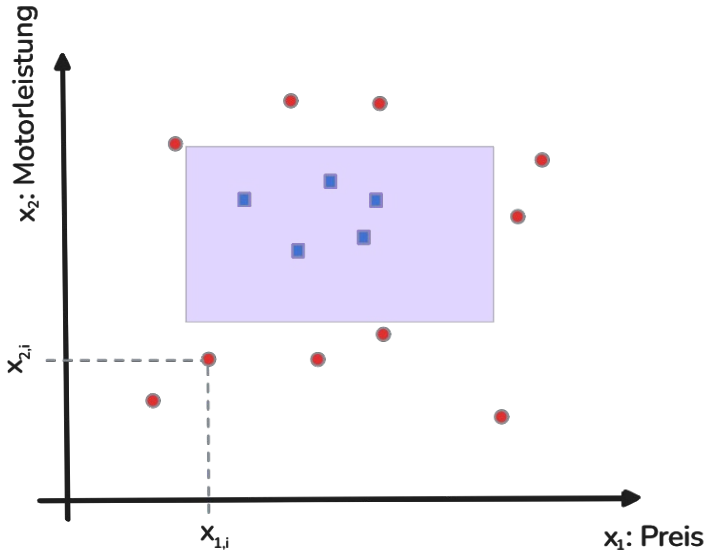
$$x_1 = \text{Preis}$$
$$x_2 = \textit{Motorleistung}$$

$$y = \begin{cases} 1 & \text{Familienauto} \\ 0 & \text{kein Familienauto.} \end{cases}$$

Hypothese *h*: (Kandidaten-)Funktion zur Klassifikation

$$h_\theta = \text{Ein konkretes Rechteck}$$

z.B. $$h_\theta = \begin{cases} 1, & 20 \leq x_1 \leq 40 \wedge 80 \leq x_2 \leq 150 \\ 0, & \text{sonst} \end{cases}$$




*aus Alpaydin, Ethem. *Introduction to Machine learning*. MIT press, 2021.

# Hypothese, Hypothesenraum und Lerner

Beispiel: Ist ein Auto ein Familienauto?*

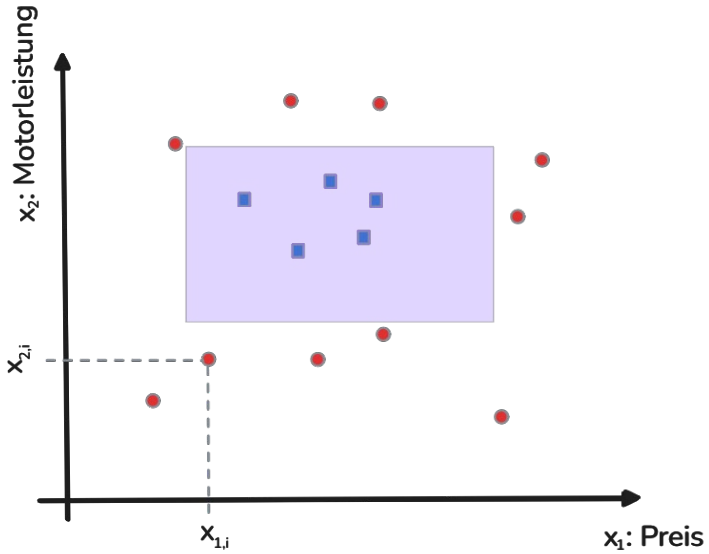
$$x_1 = \text{Preis}$$
$$x_2 = Motorleistung$$

$$y = \begin{cases} 1 & \text{Familienauto} \\ 0 & \text{kein Familienauto.} \end{cases}$$

Parameter $\theta$:

werden gelernt

z.B. $\theta = \{x_{1,1}, x_{1,2}, x_{2,1}, x_{2,2}\}$




*aus Alpaydin, Ethem. *Introduction to Machine learning*. MIT press, 2021.

# Hypothese, Hypothesenraum und Lerner

Induktiver Bias

Warum $H = \{\text{Rechtecke}\}$?

Warum nicht Kreise, Geraden, Polynome, beliebige Gebilde?

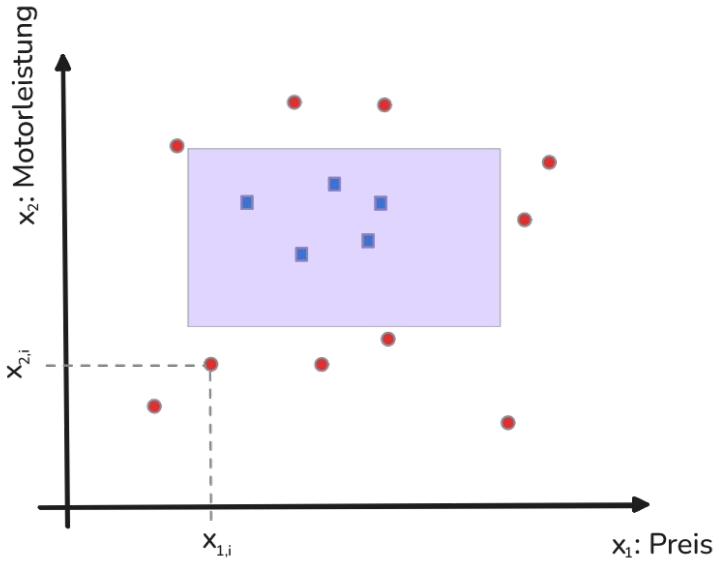
Wir treffen Annahmen und Entscheidungen!

- Linearität, Lokalität, Merkmalsauswahl

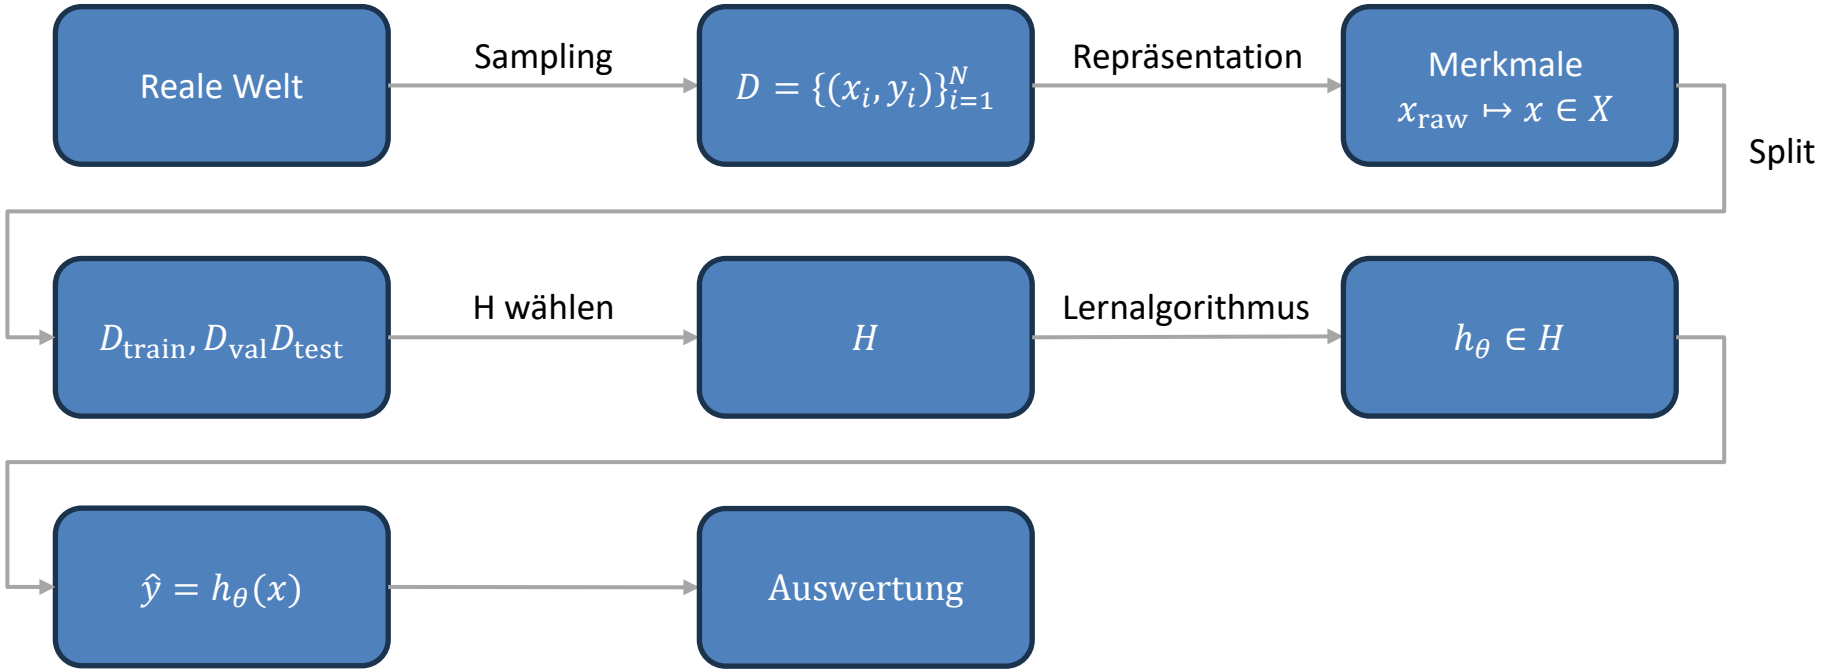
Wir entscheiden über die Struktur des Lerners!

- Baumartige Strukturen, Neuronales Netz, SVM, …

Diese Annahmen und Entscheidungen induzieren einen Bias!



# Die entstehende Pipeline

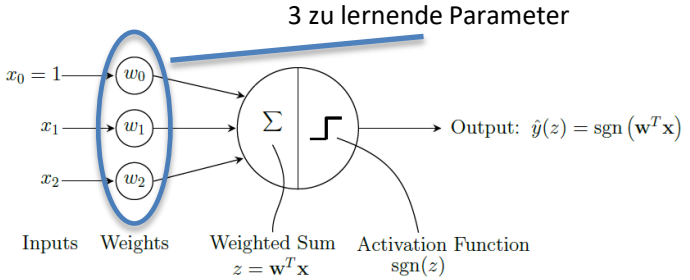


# Wie viele Daten sind genug?

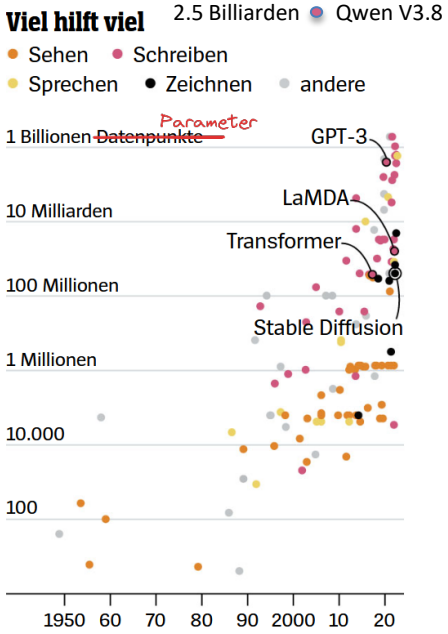
# Wie viele Daten sind genug?

**Es kommt darauf an !**

Abhängig von
- Aufgabenstellung
- Datenqualität (Rauschen, etc.)
- Anzahl notwendiger Dimensionen (siehe Curse of Dimensionality)
- Varianz in den Daten
- Modellkomplexität




vs.




Aus Der Spiegel, "Training für künstliche Intelligenz So sieht die Arbeit von Clickworkern aus"
Ursprüngliche Quelle: Villalobos, Pablo, et al. "Machine learning model sizes and the parameter gap." *arXiv preprint arXiv:2207.02852* (2022).

# Wie viele Daten sind genug?

Es kommt darauf an !

## Heart Failure Clinical Records

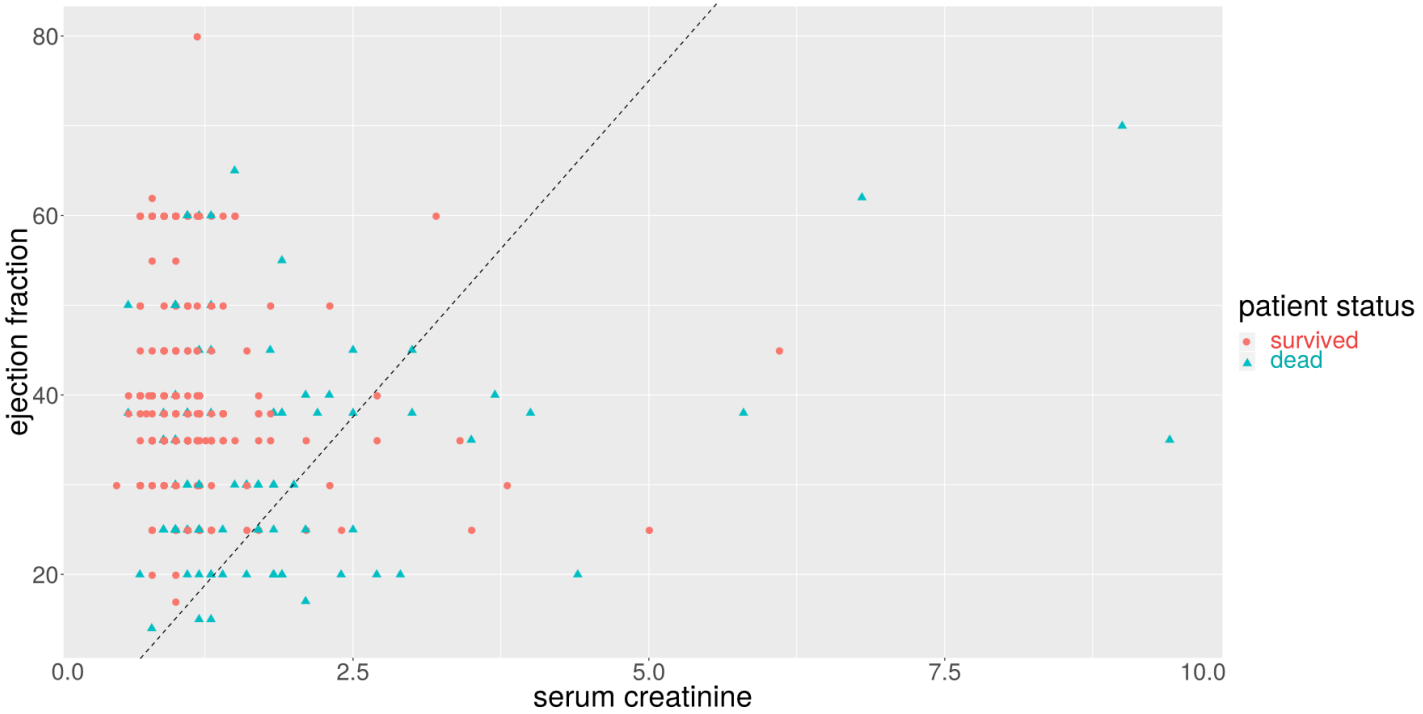
Donated on 2/4/2020

This dataset contains the medical records of 299 patients who had heart failure, collected during their follow-up period, where each patient profile has 13 clinical features.

| Dataset Characteristics | Subject Area | Associated Tasks |
|---|---|---|
| Multivariate | Health and Medicine | Classification, Regression, Clustering |
| **Feature Type** | **# Instances** | **# Features** |
| Integer, Real | 299 | 12 |

Chicco, D., Jurman, G. Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction a
*BMC Med Inform Decis Mak* **20**, 16 (2020). https://doi.org/10.1186/s12911-020-1023-5

# Wie viele Daten sind genug?



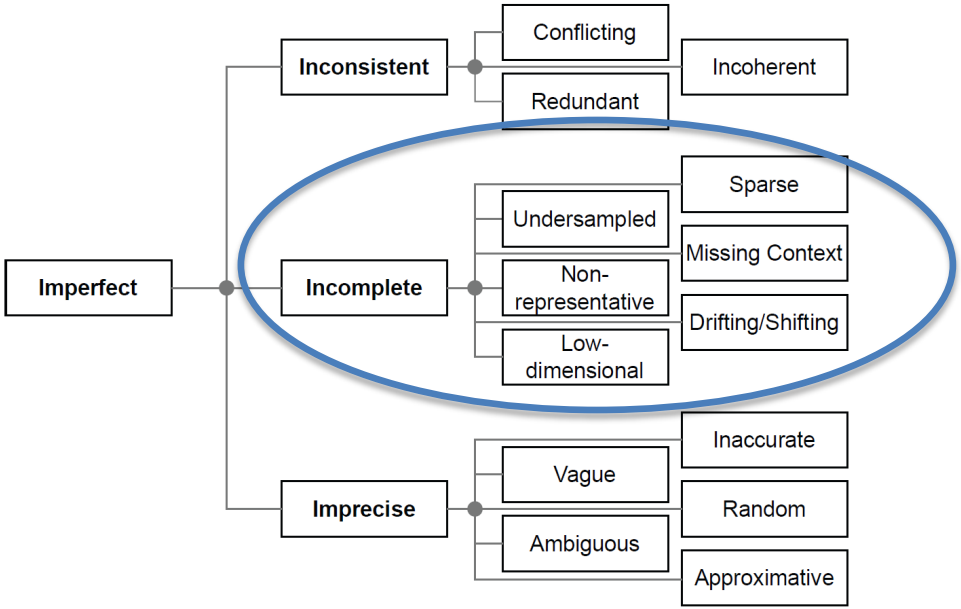

„[…] our approach showed that machine learning can be used effectively for binary classification of electronic health records of patients with cardiovascular hearth diseases.“

**Fig. 3** Scatterplot of serum creatinine versus ejection fraction. Serum creatinine (x axis) range: [0.50, 9.40] mg/dL. Ejection fraction (y axis) range: [14, 80]%. We manually drew a black straight line to highlight the discrimination between alive and dead patients

Chicco, D., Jurman, G. Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction a
*BMC Med Inform Decis Mak* **20**, 16 (2020). https://doi.org/10.1186/s12911-020-1023-5

# Wie viele Daten sind genug?

Zu wenig Daten / Erscheinungsformen

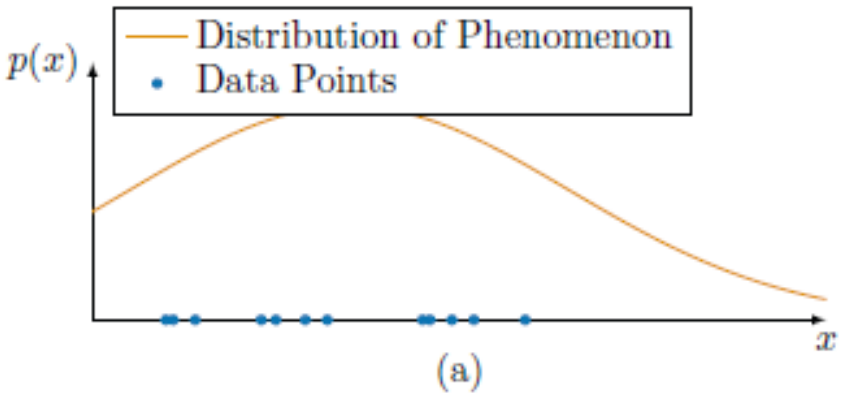


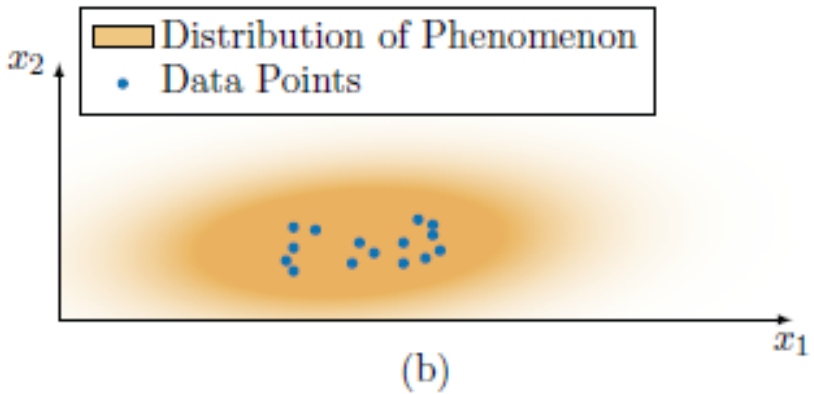

Holst, Christoph-Alexander. *Designing Possibilistic Information Fusion Systems: Redundancy as Criterion for Fusion Topologies*. Springer Nature Switzerland , 2026.

# Wie viele Daten sind genug?

Zu wenig Daten / Erscheinungsformen

Undersampled/Sample scarcity – zu wenige Beobachtungen



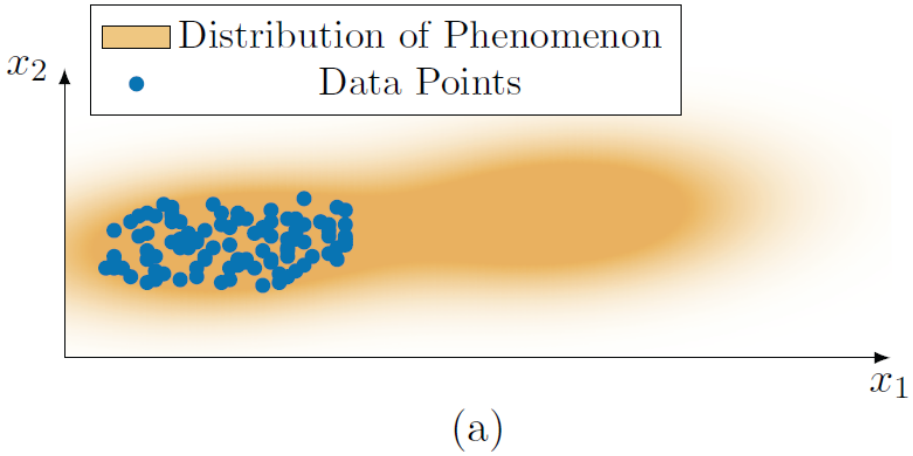




Holst, Christoph-Alexander. *Designing Possibilistic Information Fusion Systems: Redundancy as Criterion for Fusion Topologies*. Springer Nature Switzerland , 2026.

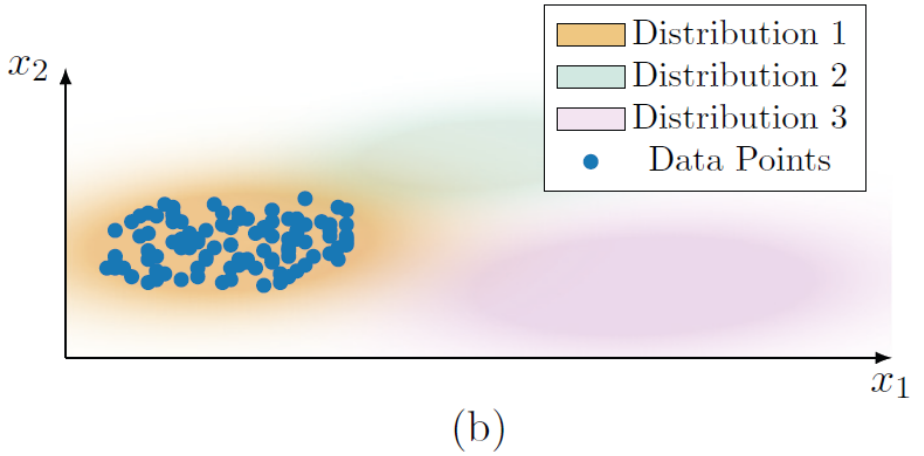
# Wie viele Daten sind genug?

Zu wenig Daten / Erscheinungsformen

Non-representative/Rare event scarcity – seltene Ereignisse fehlen




(a)




(b)

Die Anzahl der Datenpunkte ist nur ein sehr grobes Maß für die tatsächlich vorhandene Information.

Holst, Christoph-Alexander. *Designing Possibilistic Information Fusion Systems: Redundancy as Criterion for Fusion Topologies*. Springer Nature Switzerland , 2026.

# Wie viele Daten sind genug?

Zu wenig Daten / Erscheinungsformen

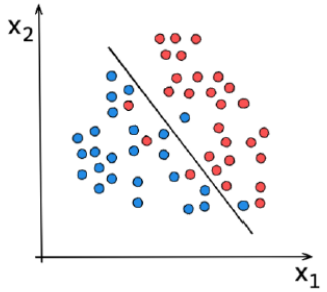
| | |
|---|---|
| Missing context | Zu wenig Label, zu wenig Expertenwissen, um alle Daten nutzen zu können |
| Sparse | Fehlende Werte (spärlich besetzte Matrix) |
| Drifting/Shifting | Konzepte verändern sich über Zeit. Daten fehlen zum Neutrainieren |

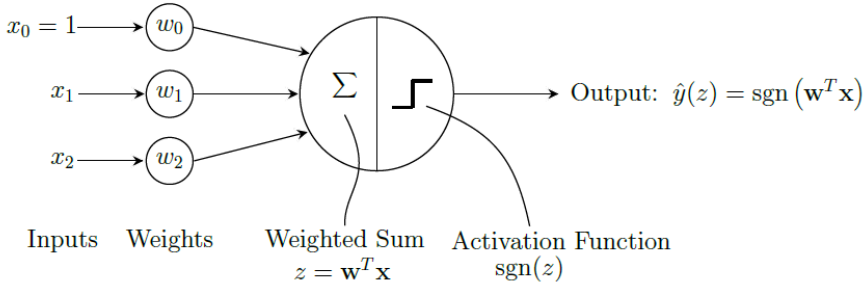
Holst, Christoph-Alexander. *Designing Possibilistic Information Fusion Systems: Redundancy as Criterion for Fusion Topologies*. Springer Nature Switzerland , 2026.

# Nächster Termin: Vom linearen Modell zum Perceptron

$$H_{\text{linear}} = \{x \mapsto w^T + b\}$$

Wie findet ein Maschineller Lerner
*w* und *b*?





Arbeitsgruppe Diskrete Systeme
Dr. Christoph-Alexander Holst
Institut für industrielle Informationstechnik (iniT)
Campusallee 6
32657 Lemgo

