Maschinelles Lernen (ML), Wintersemester 2026/27
Arbeitsgruppe Diskrete Systeme

Zusatzblatt: Herleitung der geschlossenen Lösung

Dieses Zusatzblatt ergänzt das Handout zu Übung 3 (Lineare Regression) um die Herleitung der dort in Gleichung (3) angegebenen Normalengleichung, in Matrixschreibweise.

1 Ausgangslage

Wir betrachten wie im Haupt-Handout ein einzelnes Merkmal x, eine Zielgröße y und n Trainingsbeispiele (x_i, y_i). Das Modell

$$\hat{y} = w \cdot x + b \tag{1}$$

wird anhand des mittleren quadratischen Fehlers bewertet:

$$L(w, b) = \frac{1}{n} \sum_{i=1}^{n} (w \cdot x_i + b - y_i)^2 \,. \tag{2}$$

$L(w, b)$ ist eine quadratische Funktion der Parameter w, b und damit *konvex*: Sie besitzt höchstens ein lokales Minimum, das dann automatisch auch das globale Minimum ist. An dieser Stelle verschwindet der Gradient (der Vektor aller partiellen Ableitungen). Da L konvex ist, genügt es, diese Nullstellenbedingung zu lösen. Eine zusätzliche Prüfung, ob es sich tatsächlich um ein Minimum handelt, ist nicht nötig. Das Vorgehen: Verlustfunktion in Matrixschreibweise aufstellen, Gradienten bilden, gleich Null setzen, nach dem Parametervektor auflösen.

2 Aufbau: Bias-Trick und Matrixschreibweise

Mit dem Bias-Trick aus dem Haupt-Handout sei $\theta = (b, w)^T \in \mathbb{R}^{2\times 1}$, $X_b \in \mathbb{R}^{n\times 2}$ mit Zeile i gleich $(1, x_i)$, und $\mathbf{y} \in \mathbb{R}^{n\times 1}$ der Vektor aller Zielwerte. Zeile i von $X_b\theta$ ist $1 \cdot b + x_i \cdot w = b + wx_i$, also genau $\hat{y}_i$ aus (1). Für alle n Beispiele gleichzeitig gilt somit $\hat{\mathbf{y}} = X_b\theta$.

3 Rechenregeln, die für die Herleitung gebraucht werden

a) Distributivität der Matrixmultiplikation. Für Matrizen/Vektoren passender Dimension gilt wie bei Zahlen $A(B+C) = AB+AC$ und $(A+B)C = AC+BC$. Klammern lassen sich also wie in der Schulalgebra ausmultiplizieren, mit einer Einschränkung: Die Reihenfolge der Faktoren darf dabei nie vertauscht werden, da Matrixmultiplikationen im Allgemeinen nicht kommutativ sind ($AB \neq BA$). Für zwei Spaltenvektoren $\mathbf{u}, \mathbf{v}$ ergibt sich damit dasselbe Schema wie $(a-b)(a-b) = a^2 - ab - ba + b^2$ bei Zahlen:

$$(\mathbf{u} - \mathbf{v})^T(\mathbf{u} - \mathbf{v}) = \mathbf{u}^T\mathbf{u} - \mathbf{u}^T\mathbf{v} - \mathbf{v}^T\mathbf{u} + \mathbf{v}^T\mathbf{v}.$$

b) Transponierungsregel $(AB)^T = B^TA^T$. Anschaulich passt auch nur diese Reihenfolge zusammen: Ist A eine $(m \times k)$- und B eine $(k \times n)$-Matrix, ist A^T von der Form $(k \times m)$ und B^T von der Form $(n \times k)$. Nur B^TA^T ist als Matrixprodukt definiert, A^TB^T im Allgemeinen nicht.

c) Folgerung: Ein Skalar ist gleich seiner eigenen Transponierten. Eine 1×1-Matrix hat beim Transponieren nichts zu vertauschen (nur ein Eintrag). Für jedes Skalar s, aufgefasst als 1×1-Matrix, gilt also $s^T = s$.

4 Herleitung der Lösung

Schritt 1: Die Verlustfunktion in Matrixform. Die Summe der quadrierten Fehler ist das Skalarprodukt des Fehlervektors mit sich selbst, also sein quadriertes Längenmaß:

$$L(\theta) = \frac{1}{n}\|X_b\theta - \mathbf{y}\|^2 = \frac{1}{n}\left(X_b\theta - \mathbf{y}\right)^T\left(X_b\theta - \mathbf{y}\right).$$

Schritt 2: Ausmultiplizieren. Mit der Distributivität (a) folgt

$$\begin{aligned}\left(X_b\theta - \mathbf{y}\right)^T\left(X_b\theta - \mathbf{y}\right) &= (X_b\theta)^T(X_b\theta) - (X_b\theta)^T\mathbf{y} - \mathbf{y}^T(X_b\theta) + \mathbf{y}^T\mathbf{y} \\ &= \theta^T X_b^T X_b\theta - \theta^T X_b^T\mathbf{y} - \mathbf{y}^T X_b\theta + \mathbf{y}^T\mathbf{y},\end{aligned}$$

wobei im zweiten Schritt die Transponierungsregel (b) auf $(X_b\theta)^T$ angewendet wurde. Die beiden mittleren Terme sehen unterschiedlich aus, sind aber gleich: $\mathbf{y}^T X_b\theta$ ist als Produkt $(1\times n)(n\times 2)(2\times 1)$ ein Skalar, nach (c) also gleich seiner eigenen Transponierten, und mit der Transponierungsregel (b) folgt

$$\mathbf{y}^T X_b\theta = \left(\mathbf{y}^T X_b\theta\right)^T = \theta^T X_b^T\mathbf{y}^{TT} = \theta^T X_b^T\mathbf{y}.$$

Damit lassen sich die beiden mittleren Terme zu einem Term mit Faktor 2 zusammenfassen:

$$L(\theta) = \frac{1}{n}\left[\theta^T X_b^T X_b\theta - 2\,\theta^T X_b^T\mathbf{y} + \mathbf{y}^T\mathbf{y}\right]. \tag{3}$$

Schritt 3: Gradientenbildung. Dafür werden drei Regeln der Vektor-Differentialrechnung benötigt (Tabelle 1), die sich direkt an die gewöhnliche Kurvendiskussion anlehnen.

Tabelle 1: Benötigte Rechenregeln der Vektor-Differentialrechnung (A symmetrisch, $\mathbf{c}$ konstanter Vektor) und ihre skalare Analogie.

Regel	Skalare Analogie
$\nabla_\theta\left(\theta^T A\theta\right) = 2A\theta$	$\frac{d}{dx}(ax^2) = 2ax$
$\nabla_\theta\left(\theta^T\mathbf{c}\right) = \mathbf{c}$	$\frac{d}{dx}(cx) = c$
Konstante ohne θ $\rightarrow$ Gradient $\mathbf{0}$	$\frac{d}{dx}(\text{const.}) = 0$

$A := X_b^T X_b$ ist symmetrisch, was direkt aus der Transponierungsregel folgt: $(X_b^T X_b)^T = X_b^T(X_b^T)^T = X_b^T X_b$. Die erste Regel ist also anwendbar. Mit $A = X_b^T X_b$ und $\mathbf{c} = X_b^T\mathbf{y}$ ergibt sich Term für Term aus Gleichung (3):

$$\nabla_\theta L(\theta) = \frac{1}{n}\left[2X_b^T X_b\theta - 2X_b^T\mathbf{y}\right] = \frac{2}{n}\left(X_b^T X_b\theta - X_b^T\mathbf{y}\right).$$

Schritt 4: Gradient gleich Nullvektor setzen. Multiplikation mit $n/2$ und Umstellen ergibt

$$X_b^T X_b \, \theta = X_b^T \mathbf{y}.$$

Schritt 5: nach θ auflösen. Ist $X_b^T X_b$ invertierbar, multiplizieren wir von links mit $\left(X_b^T X_b\right)^{-1}$:

$$\left(X_b^T X_b\right)^{-1} X_b^T X_b \, \theta = \left(X_b^T X_b\right)^{-1} X_b^T \mathbf{y} \implies \theta = \left(X_b^T X_b\right)^{-1} X_b^T \mathbf{y}.$$

Dies entspricht der Normalengleichung aus dem Handout zu Übung 3.

5 Gültigkeitsbedingung

Die hier hergeleitete Normalengleichung setzt voraus, dass $X_b^T X_b$ invertierbar ist. Das ist eine Bedingung an die Daten, keine Garantie dafür, dass überhaupt eine geschlossene Lösung existiert. Für Modelle oder Verlustfunktionen außerhalb des hier betrachteten Falls (lineares Modell, quadratischer Verlust) führt das Nullsetzen des Gradienten schon auf kein lineares Gleichungssystem.

$X_b^T X_b$ ist eine 2×2-Matrix und invertierbar genau dann, wenn die beiden Spalten von X_b (Einsen-Spalte und x-Spalte) linear unabhängig sind. Dafür braucht es mindestens zwei Datenpunkte, deren x-Werte sich zudem unterscheiden müssen. Sind alle x_i gleich, ist die x-Spalte ein Vielfaches der Einsen-Spalte, und die Matrix wird singulär.

Anschauliche Interpretation: Variiert x nicht, steckt in den Daten keine Information darüber, wie stark y auf Änderungen von x reagiert. Die Steigung ist damit unbestimmt.